

# SLAM

## 1. 传感器

### 1.1. 相机

#### 1.1.1. 相机模型

##### 1.1.1.1. 针孔相机模型

#### 1.1.2. 相机分类

### 1.2. 激光雷达

#### 1.2.1. 机械旋转式激光雷达

#### 1.2.2. 固态激光雷达

### 1.3. IMU

## 2. 几何变换与位姿轨迹对齐

### 2.1. 旋转的几种表示方式

### 2.2. 几何变换

### 2.3. Umeyama算法求解sim3变换

#### 2.3.1. 理论推导

#### 2.3.2. Umeyama算法实现流程

## 3. 多视图几何

### 3.1. 对极约束

### 3.2. 三角化

### 3.3. PnP

#### 3.3.1. 迭代非线性优化的PnP

#### 3.3.2. EPnP

##### 3.3.2.1. 理论推导

##### 3.3.2.2. 实现流程

### 3.4. ICP(属于多视图几何吗?)

## 4. 特征提取与匹配

### 4.1. SIFT

#### 4.1.1. 尺度空间极值检测

#### 4.1.2. 关键点定位

#### 4.1.3. 方向分配

#### 4.1.4. 关键点描述子

### 4.2. ORB

### 4.3. OpenCV特征提取与匹配

## 5. 线性方程组与非线性优化

### 5.1. 线性方程组

### 5.2. 非线性优化问题的数学模型

### 5.3. Ceres非线性优化

#### 5.3.1. 构造代价函数

- 5.3.2. 构建优化问题
- 5.3.3. 配置并运行求解器
- 5.4. g2o非线性优化

# SLAM


概述: <https://www.it610.com/article/1548921238750040064.htm>

## 1. 传感器

### 1.1. 相机

#### 1.1.1. 相机模型

##### 1.1.1.1. 针孔相机模型



$$su = K [R \quad t] \begin{bmatrix} P \\ 1 \end{bmatrix} \quad (1)$$

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \quad u = \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}, \quad P = \begin{bmatrix} X \\ Y \\ Z \end{bmatrix}_{\text{world}} \quad (2)$$

畸变模型\*\*

1.1.2. 相机分类

<https://zhuanlan.zhihu.com/p/371410573>

1.2. 激光雷达

1.2.1. 机械旋转式激光雷达

1.2.2. 固态激光雷达

1.3. IMU

2. 几何变换与位姿轨迹对齐

2.1. 旋转的几种表示方式

表示方法	Eigen类	初始化
欧拉角		
旋转矩阵 (3×3)	Eigen::Matrix3d	
旋转向量 (3×1)	Eigen::AngleAxisd	
四元数 (4×1)	Eigen::Quaterniond	

pitch、yaw、roll

2.2. 几何变换

几何变换位于Eigen的Geometry模块

变换名称	矩阵形式	自由度	Eigen类 (以double数据类型为例)
旋转变换 (SO3)	$R$		
欧式变换 (SE3)、刚体变换	$T = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix}$		
相似变换 (Sim3)	$T = \begin{bmatrix} cR & t \\ 0 & 1 \end{bmatrix}$		
仿射变换 (线性变换+平移)	$T = \begin{bmatrix} A & t \\ 0 & 1 \end{bmatrix}$		Eigen::Affine3d
射影变换			Eigen::Projective3d

## 2.3. Umeyama算法求解sim3变换

### 2.3.1. 理论推导

Umeyama算法、ICP算法、Sim3: <https://zhuanlan.zhihu.com/p/532444005>,

<https://zhuanlan.zhihu.com/p/274504142>,

[https://blog.csdn.net/weixin\\_42823098/article/details/111308627?spm=1001.2101.3001.6650.3&utm\\_medium=distribute.pc\\_relevant.none-task-blog-2%7Edefault%7ECTRLIST%7ERate-3-111308627-blog-108800676.pc\\_relevant\\_layerdownloadsortv1&depth\\_1-utm\\_source=distribute.pc\\_relevant.none-task-blog-2%7Edefault%7ECTRLIST%7ERate-3-111308627-blog-108800676.pc\\_relevant\\_layerdownloadsortv1&utm\\_relevant\\_index=5](https://blog.csdn.net/weixin_42823098/article/details/111308627?spm=1001.2101.3001.6650.3&utm_medium=distribute.pc_relevant.none-task-blog-2%7Edefault%7ECTRLIST%7ERate-3-111308627-blog-108800676.pc_relevant_layerdownloadsortv1&depth_1-utm_source=distribute.pc_relevant.none-task-blog-2%7Edefault%7ECTRLIST%7ERate-3-111308627-blog-108800676.pc_relevant_layerdownloadsortv1&utm_relevant_index=5)

参考文献: \* "Least-squares estimation of transformation parameters between two point patterns",

\* Shinji Umeyama, PAMI 1991, DOI: 10.1109/34.88573

$$e^2(\mathbf{R}, \mathbf{t}, c) = \frac{1}{n} \sum_{i=1}^n \|\mathbf{y}_i - (c\mathbf{R}\mathbf{x}_i + \mathbf{t})\|^2 \quad (3)$$

### 2.3.2. Umeyama算法实现流程

(1) 分别计算两组点的质心 $(\bar{x}, \bar{y})$ 、去质心坐标 $(\mathbf{x}', \mathbf{y}')$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \quad (4)$$

$$\mathbf{x}' = \mathbf{x}_i - \bar{x}, \mathbf{y}' = \mathbf{y}_i - \bar{y} \quad (5)$$

(2) 分别计算两组点的方差系数 $(\sigma_x, \sigma_y)$ 、协方差矩阵 $H$

$$\sigma_x = \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}'_i\|^2, \sigma_y = \frac{1}{n} \sum_{i=1}^n \|\mathbf{y}'_i\|^2 \quad (6)$$

$$\mathbf{H} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}'_i \mathbf{y}'_i^T \quad (7)$$

(3) 对 $H$ 进行SVD分解, 求解最优旋转矩阵 $\mathbf{R}^*$

$$\mathbf{H} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (8)$$

$$\mathbf{M} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \det(\mathbf{V}\mathbf{U}^T) \end{bmatrix} \quad (9)$$

$$\mathbf{R}^* = \mathbf{V}\mathbf{M}\mathbf{U}^T \quad (10)$$

(4) 利用最优解 $\mathbf{R}^*$ 求解尺度参数 $c$

$$c^* = \frac{D^*}{\sigma_x} = \frac{\text{tr}(\mathbf{M}\mathbf{\Sigma})}{\sigma_x} \quad (11)$$

(6) 利用最优解计算 $t$

$$\mathbf{t}^* = \bar{\mathbf{y}} - \mathbf{s}^* \mathbf{R}^* \bar{\mathbf{x}} \quad (12)$$

Umeyama算法位于Eigen源码Geometry模块的Umeyama.h头文件中

### 3. 多视图几何

#### 3.1. 对极约束

#### 3.2. 三角化

#### 3.3. PnP

##### 3.3.1. 迭代非线性优化的PnP

$$\mathbf{T}^* = \arg \min_{\mathbf{T}} \|\mathbf{e}_i\|^2 = \arg \min_{\mathbf{T}} \sum_{i=1}^n \left\| \mathbf{u}_i - \frac{1}{s_i} \mathbf{K} [\mathbf{R} \quad \mathbf{t}] \begin{bmatrix} \mathbf{p}_i \\ 1 \end{bmatrix} \right\|^2 \quad (13)$$

##### 3.3.2. EPnP

###### 3.3.2.1. 理论推导

使用世界坐标系中四个虚拟控制点的线性组合来表示全体 $n$ 个地图点坐标 $\mathbf{p}_i^w (i = 1, 2, \dots, n)$ ，根据相机外参得到相机坐标系下地图点坐标 $\mathbf{p}_i^c$ 和控制点坐标 $\mathbf{c}_j^c$ 之间的关系

$$\mathbf{p}_i^w = \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^w, \quad \mathbf{p}_i^c = \sum_{j=1}^4 \alpha_{ij} \mathbf{c}_j^c \quad (14)$$

式中:  $\sum_{j=1}^4 \alpha_{ij} = 1$ ,  $\alpha_{ij}$ 称为齐次重心坐标 (homogeneous barycentric coordinates)。

$$s_i \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \sum_{j=1}^4 \alpha_{ij} \begin{bmatrix} x_j^c \\ y_j^c \\ z_j^c \end{bmatrix} \quad (15)$$

消去 $s_i$ 得到如下等式

$$\begin{cases} \sum_{j=1}^4 \alpha_{ij} f_x x_j^c + \alpha_{ij} (c_x - u_i) z_j^c = 0 \\ \sum_{j=1}^4 \alpha_{ij} f_y y_j^c + \alpha_{ij} (c_y - v_i) z_j^c = 0 \end{cases} \quad (16)$$

若有 $n$ 个点，则构成线性方程组

$$\mathbf{M} \mathbf{x} = \mathbf{0} \quad (17)$$

式中:  $\mathbf{M}_{2n \times 12}$ ,  $\mathbf{x} = [(\mathbf{c}_1^c)^T \quad (\mathbf{c}_2^c)^T \quad (\mathbf{c}_3^c)^T \quad (\mathbf{c}_4^c)^T]^T$ , 上述方程的解是属于系数矩阵 $\mathbf{M}$ 的零空间，可以由线性组合的形式表示

$$\mathbf{x} = \sum_{i=1}^N \beta_i \mathbf{v}_i \quad (18)$$

式中:  $v_i (i = 1, 2, \dots, N)$  为矩阵  $M$  的  $N$  个零奇异值对应的右奇异向量,  $\beta_i (i = 1, 2, \dots, N)$  为系数项,  $N$  可以是 1~4 之间的任意值, 对此原文作者分别详细给出了  $N = 1, 2, 3, 4$  时  $\beta_i$  的具体求解方法。

**注意: 向量  $v$  的维数是多少? ? ?  $c_i$  怎么用  $v_i$  线性表示? ? ? 怎么解释原文公式 (16) ? ? ?**

通过最小化两个坐标系下控制点间距差来计算系数项  $\beta = [\beta_1 \ \beta_2 \ \beta_3 \ \beta_4]^T$

$$\text{Error}(\beta) = \sum_{(i,j) \text{ s.t. } i < j} \left( \|c_i^c - c_j^c\|^2 - \|c_i^w - c_j^w\|^2 \right) \quad (19)$$

求解  $R, t$

### 3.3.2.2. 实现流程

EPnP: 以 OpenCV 为例

参考文献: [EPnP An Accurate O\(n\) Solution to the PnP Problem.pdf](#)

<https://zhuanlan.zhihu.com/p/361791835>

## 3.4. ICP(属于多视图几何吗? )

# 4. 特征提取与匹配

## 4.1. SIFT

### 4.1.1. 尺度空间极值检测

级联过滤方法检测关键点。通过使用被称为尺度空间的连续尺度函数, 在所有可能的尺度上搜索稳定特征, 实现对图像尺度变化不变的位置的检测。

尺度空间  $L(x, y, \sigma)$  定义为变尺度高斯函数  $G(x, y)$  与图像  $I(x, y)$  的卷积

$$L(x, y, \sigma) = G(x, y, \sigma) \cdot I(x, y) \quad (20)$$

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (21)$$


使用高斯差分函数 (Difference of Gaussian, DOG) 实现有效检测尺度空间中稳定的关键点位置, 该函数是由常数乘因子  $k$  分隔的两个相邻尺度的差分

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) \cdot I(x, y) = L(x, y, k\sigma) - L(x, y, \sigma) \quad (22)$$

初始图像与高斯函数进行增量卷积, 生成下图左列所示的被常数因子  $k$  分隔的尺度空间图像集。

我们选择将尺度空间的每个八度(即  $\sigma$  的两倍)分成一个整数  $s$ , 即  $k = 2^s/s$

对于尺度空间的每个八度, 将初始图像与高斯函数进行反复卷积, 生成左图所示的尺度空间图像集。对相邻的高斯图像进行相减, 得到右边的高斯图像差。在每一个八度之后, 高斯图像被降低采样 2 倍, 并重复这个过程



#### 4.1.2. 关键点定位

#### 4.1.3. 方向分配

#### 4.1.4. 关键点描述子

[https://blog.csdn.net/lavender19/article/details/120396145?spm=1001.2101.3001.6650.6&utm\\_medium=distribute.pc\\_relevant.none-task-blog-2%7Edefault%7EBlogCommendFromBaidu%7ERate-6-120396145-blog-118003686.pc\\_relevant\\_3mothn\\_strategy\\_recovery&depth\\_1-utm\\_source=distribute.pc\\_relevant.none-task-blog-2%7Edefault%7EBlogCommendFromBaidu%7ERate-6-120396145-blog-118003686.pc\\_relevant\\_3mothn\\_strategy\\_recovery&utm\\_relevant\\_index=11](https://blog.csdn.net/lavender19/article/details/120396145?spm=1001.2101.3001.6650.6&utm_medium=distribute.pc_relevant.none-task-blog-2%7Edefault%7EBlogCommendFromBaidu%7ERate-6-120396145-blog-118003686.pc_relevant_3mothn_strategy_recovery&depth_1-utm_source=distribute.pc_relevant.none-task-blog-2%7Edefault%7EBlogCommendFromBaidu%7ERate-6-120396145-blog-118003686.pc_relevant_3mothn_strategy_recovery&utm_relevant_index=11)

[https://blog.csdn.net/Robert\\_Q/article/details/118003686](https://blog.csdn.net/Robert_Q/article/details/118003686)

### 4.2. ORB

### 4.3. OpenCV特征提取与匹配

cv::keypoint类的成员变量包括哪些：位置、方向、角度、金字塔层数？？

## 5. 线性方程组与非线性优化

### 5.1. 线性方程组

线性方程组的几种分解方法：svd，QR、LU、

### 5.2. 非线性优化问题的数学模型

### 5.3. Ceres非线性优化

```
1
2 ceres::Problem
3 ceres::Solver::Options
4 ceres::Solver::Summary
5 ceres::CostFunction
6
7 // 求解器类ceres::Solver中的Solve函数来求解非线性优化问题，引用的三个参数中
  包含三个重要的类ceres::Problem 、ceres::Solver::Options、
  ceres::Solver::Summary
8 CERES_EXPORT void solve(const Solver::Options& options,
9                           Problem* problem,
10                          Solver::Summary* summary);
```

### 5.3.1. 构造代价函数

### 5.3.2. 构建优化问题

### 5.3.3. 配置并运行求解器

## 5.4. g2o非线性优化